

Inferencia Estadística y Modelado

Empresa: TechStore Analytics

Dataset: techstore_data.csv

1. Contexto Gerencial

TechStore es una empresa de e-commerce en expansión especializada en productos tecnológicos que opera en cuatro regiones del país. Hace tres meses implementaron un chatbot con Inteligencia Artificial como piloto y ahora poseen datos de 500 transacciones.

La gerencia necesita ir más allá del análisis descriptivo y requiere validar afirmaciones, estimar parámetros poblacionales y predecir comportamientos futuros para tomar decisiones sobre la continuidad del chatbot y las estrategias regionales.

2. Variables del Estudio

Para este análisis inferencial, utilizará principalmente las siguientes variables :

- **Variables Cuantitativas:** monto_compra (Variable Objetivo), tiempo_navegacion, productos_vistos, satisfaccion.
- **Variables Categóricas:** region, uso_chatbot_ia, tipo_cliente.

Módulo A: Estimación y Tamaño de Muestra

El equipo de marketing planea realizar nuevos estudios y necesita determinar la viabilidad estadística de sus métricas actuales.

1. Cálculo de Tamaño de Muestra:

- **Para la media:** ¿Qué tamaño de muestra se necesita para estimar el monto_compra promedio con un error máximo de \$10 y un nivel de confianza del 95%? Utilice la desviación estándar poblacional calculada previamente.
- **Para la proporción:** ¿Qué tamaño de muestra se requiere para estimar la proporción de clientes que usan el chatbot con un error del 3% y un 99% de confianza?.

2. Intervalos de Confianza:

- Construya e interprete un Intervalo de Confianza (IC) del 95% para el **monto promedio de compra** de los clientes categorizados como Premium.

- Construya e interprete un IC del 90% para la **proporción** de clientes que usan el uso_chatbot_ia.

Módulo B: Pruebas de Hipótesis (Paramétricas y No Paramétricas)

La gerencia tiene creencias específicas sobre el negocio que deben ser validadas o rechazadas estadísticamente con un nivel de significancia del 5% ($\alpha = 0.05$).

1. Prueba T de una muestra (Validación de KPI):

- La gerencia afirma que el monto promedio de compra global es de **\$350**. Plantee las hipótesis nula (H_0) y alternativa (H_1), realice la prueba t, calcule el p-valor y concluya si la afirmación es sostenible .

2. Prueba Chi-Cuadrado de Independencia:

- Se desea saber si la adopción del chatbot depende de la ubicación geográfica.
- **Hipótesis:**
 - H_0 : El uso_chatbot_ia es independiente de la region.
 - H_1 : Existe relación entre el uso del chatbot y la región.
- Genere la tabla de contingencia y realice la prueba. ¿La adopción es uniforme en todo el país?

3. ANOVA de Dos Factores (Análisis de Varianza):

- Analice si el monto_compra se ve afectado por la region (Factor A) y el uso_chatbot_ia (Factor B).
- Determine si existen efectos principales significativos por región o por uso de chatbot, y si existe una **interacción** entre ambos factores.

Módulo C: Modelado Predictivo (Regresión Lineal Múltiple)

El objetivo final es construir un modelo que permita estimar el valor de las transacciones basándose en el comportamiento de navegación.

Variable Dependiente (Y): monto_compra

Variables Independientes (X): tiempo_navegacion, productos_vistos, satisfaccion.

1. Selección de Variables y Multicolinealidad:

- Genere una matriz de correlación e identifique variables con correlación fuerte ($r > 0.7$).
- Construya un modelo inicial y calcule el VIF (Factor de Inflación de Varianza). Si alguna variable tiene un $VIF > 10$, elimínela para corregir la multicolinealidad.

2. Ajuste y Depuración del Modelo:

- Realice un proceso iterativo eliminando las variables que no sean estadísticamente significativas ($p\text{-valor} > 0.05$) hasta obtener un modelo final robusto.
- Presente la ecuación final de regresión.

3. Validación de Supuestos:

- Verifique gráficamente los supuestos de Linealidad, Normalidad (Q-Q plot), y Homocedasticidad del modelo final.

4. Predicción y Toma de Decisiones:

- Utilizando el modelo final, prediga el monto de compra para un **"Cliente Promedio con Chatbot"** que tiene los siguientes valores:
 - tiempo_navegacion: Mediana del dataset.
 - productos_vistos: Mediana del dataset.
 - satisfaccion: Mediana del dataset.
- Basado en los coeficientes estandarizados: ¿Qué variable tiene mayor influencia en el monto de compra y qué estrategia recomendaría para aumentarla?.